

CNNとVision Transformerに よる画像分類性能の比較

B2240540 3-C 20 小野渉

背景・目的

- 授業内の画像分析(CNN)では正解率があまり高くなかった
 - より性能を高めたい
- ↓
- Vision Transformer (ViT) を用いて分析を行ってみる
 - 精度や学習時間を比較し各モデルの特徴を調べる

各手法について

- CNN(Convolutional Neural Network)

畳み込みニューラルネットワーク

- 特徴

- 入力画像データから「局所的な特徴」を抽出して分類を行う
 - 小さい範囲に分けて見ていき、耳や目などのような特徴を探していく
 - この小さい範囲の窓を少しずつ動かすことを畳み込みという
 - 畳み込みとプーリング(必要な情報だけ残していく)を繰り返して全結合層へ
- 通常ニューラルネットワークより層が深い
- …畳み込み層があるため

各手法について

- ViT(Vision Transformer)

Transformerを画像認識に応用したモデル

- 特徴

- 画像全体をパッチ(16*16の小さな画像)に分割する
- それぞれを単語のように扱ってTransformerで処理
- Self-Attention：犬なら、耳、目、しっぽ…が全部関係してて、それらが重要、背景はあまり重要じゃないのように重要度を計算
- 今回は事前学習済みモデル（pretrained=True）を用いた転移学習を適用し、画像を224×224ピクセルへリサイズして学習を行う。
 - →事前にImageNet(非常に多い画像、約1,400万枚)から、○○とはこういう特徴があるということを事前に学習している
 - Falseだと与えられた画像から○○ってこういう特徴があるのかということを1から学ぶ

各モデルの設定条件


項目	CNN	ViT
データセット	CIFAR-10	CIFAR-10
Epoch	20	20
Optimizer	Adam	Adam
Loss	CrossEntropy	CrossEntropy
入力画像	32×32	224×224
事前学習	-	ImageNet

実行結果


項目	CNN	ViT
Accuracy	63.9%	97.29%
Loss	1.8223	0.1502
学習時間	97秒	8247秒

CNNとViTの比較(accuracy)

CNN




ViT




CNNとViTの比較(loss)

CNN




ViT




CNNとViTの比較(混同行列)

CNN



ViT



比較結果まとめ

- 精度(正解率・誤差)だけで見ると、ViTがかなり優勢
- 学習時間がとてつもない時間かかっている(約2時間)
- catとdogや、carとtruckなど、どちらのモデルも判別が比較的難しい部分が存在する

まとめ・今後の展望

- 精度重視ならViT、速度重視ならCNNといった使い分けが重要
- ViTの設定で、 pretrained=Trueで行っていたため精度が非常に高く出ていたと考えられる
↓
- pretrained=Falseでも比較を行っていききたい